

auto_ml

이진 분류(0/1) 문제를 자동으로 학습·스코어링하는 사내 라이브러리. 폐쇄 환경 이관 / 운영을 전제로 모듈화·설정 주도(YAML)로 설계되었다.

구성

auto_ml/	
├ config.py	설정 dataclass + YAML 로더
├ pipeline.py	학습 파이프라인 (auto-ml-train)
├ preprocessing/	1) 결측 → 2) 이상치 → 2.5) skew 변환 → 3) 스케일링
├ feature_selection/	Stability Selection 변수 선택
├ models/	LGBM / XGBoost / CatBoost / ElasticNet 래퍼 + Ensemble
+ Trainer	
├ tuning/	Optuna 베이지안 하이퍼파라미터 최적화
├ reporting/	HTML + PDF 리포트 (동일 내용)
├ scoring/	배치 스코어링 (auto-ml-score)
└ utils/	io / logger / validation

5단계 파이프라인

1. **전처리** — 결측 → 이상치 → skew 변환 → 스케일링 순서 고정. 학습 시 통계량을 저장해 스코어링 시 동일 적용.
2. **변수 선택** (선택) — Stability Selection (Meinshausen & Bühlmann, 2010). 전처리 직후 적용하여 안정적으로 선택되는 변수만 모델에 전달한다. `feature_selection.enabled: false` (기본값) 이면 건너뛴다.
3. **모형 적합** — LGBM / XGBoost / CatBoost / ElasticNet 4종에 대해 (a) Optuna TPE 로 하이퍼파라미터 베이지안 최적화 → (b) StratifiedKFold OOF 평가 → (c) 학습 전체로 최종 fit → (d) 테스트 데이터로 평가. 개별 모델 학습 완료 후 `ensemble.enabled: true` 이면 가중 평균 앙상블을 자동으로 추가 생성한다. `primary_metric` (기본 ROC-AUC) 기준으로 best 모델(앙상블 포함)을 선정한다.
4. **보고서 산출** — HTML / PDF 동일 내용 (Jinja2 + WeasyPrint). 모델 비교표, CV(OOF) 비교, **오버핏 점검 (Train vs Holdout, Δ)**, 튜닝 결과, ROC / PR 곡선, feature importance, score 분포, confusion matrix 포함.
5. **주기 스코어링** — 단일 artifact (preprocessor + model + metadata) 파일 1개 + 설정 YAML 1개로 운영 가능. cron 등에서 `auto-ml-score` 호출.

입력 데이터

- 학습 / 평가 데이터를 **별도 Parquet 파일** 로 받는다 (`train_data_path` , `test_data_path`). 내부에서 임의의 분할하지 않는다.
- 학습/스코어링에 사용할 컬럼은 **CSV 파일** 로 명시한다. YAML 에서 `features_csv` 에 경로를 지정하면 `load_config` 가 자동으로 읽어 `cfg.features` 를 채운다.

CSV 형식 (필수 컬럼: `name` , `type` , `used`):

```
name,type,used
age,continuous,true
gender,category,true
income,continuous,true
internal_score,continuous,false
```

- `type`
- `continuous` — 연속형 (int / float). 결측치·이상치·skew 변환·스케일링 적용.
- `category` — 범주형 (문자열 / 코드). 모델 래퍼에서 자체 인코딩 처리.
- `used`
- `true` 인 행만 학습/스코어링에 사용된다 (`false` /공백 → 제외).
- 운영 중 컬럼을 켜고 끌 때 코드 변경 없이 본 CSV 만 수정하면 된다.

```
features_csv: ./configs/features.csv
```

결측치 처리

전처리 1단계. 학습 데이터에서 컬럼별 채움 값을 계산해 저장하고, 스코어링 시 동일하게 적용한다. 학습/스코어링 일관성을 보장한다.

```
preprocessing:
  numeric_null_strategy: median          # median | mean | constant
  numeric_null_fill_value: 0.0           # constant 일 때만 사용
  categorical_null_strategy: most_frequent # most_frequent | constant
  categorical_null_fill_value: MISSING    # constant 일 때만 사용
```

- 수치형 전략: `median` (이상치에 강건, 기본) / `mean` / `constant` .
- 범주형 전략: `most_frequent` (기본) / `constant` .
- **전부-NaN 가드**: 학습 데이터에서 어떤 수치형 컬럼이 전부 NaN 이면 `median` / `mean` 으로 채움 값을 계산할 수 없어 `silent NaN` 전파를 막기 위해 명시적 `ValueError` 로 실패한다. `features.csv` 에서 해당 컬럼의 `used` 를 `false` 로 두거나 `constant` 전략으로 전환.

- 별도로 `PreprocessingPipeline.fill_missing_columns(df)` 가 스코어링 시 **컬럼 자체가 통째로 누락**된 케이스에 대비해 학습 시 산출한 기본값 (수치형 `median`, 범주형 최빈값) 으로 채워준다. 부분 NaN 은 imputer 가 처리.

이상치 처리 (백분위수 원저라이징)

전처리 2단계. 학습 데이터의 컬럼별 분위수 (`quantile(lower_q)`, `quantile(upper_q)`) 를 경계로 사용해 원저라이징하고, 스코어링 시 학습 시 저장한 동일 경계를 그대로 적용한다.

```
preprocessing:
  outlier_method: percentile      # percentile | none
  outlier_lower_quantile: 0.01
  outlier_upper_quantile: 0.99
  outlier_action: clip           # clip | null_then_impute
```

- `outlier_method`
- `percentile` — 학습 분포의 (`lower_q`, `upper_q`) 분위수를 경계로 사용. (기본)
- `none` — 비활성.
- `outlier_action`
- `clip` — 경계 밖 값을 경계로 잘라낸다. (기본)
- `null_then_impute` — 경계 밖을 NaN 으로 만든 뒤 학습 시 `median` 으로 다시 채운다.
- `outlier_lower_quantile < outlier_upper_quantile` 이고 둘 다 `[0, 1]` 범위여야 한다 (위반 시 `ValueError`).

Skew 변환

전처리 2.5단계. 학습 데이터의 컬럼별 `skew` 를 측정해 임계값 초과인 변수만 자동으로 선택해 분포를 대칭화한다. 학습 시 추정된 변환 파라미터를 저장해 스코어링에 동일 적용한다.

```
preprocessing:
  skew_method: signed_log1p      # signed_log1p | quantile_normal | none
  skew_threshold: 1.0           # |skew| > threshold 인 컬럼만 변환
```

- `skew_method`
- `signed_log1p` — `sign(x) * log1p(|x|)`. 음수까지 단조 보존, 무상태. (기본)
- `quantile_normal` — `sklearn QuantileTransformer` 로 학습 분포의 분위수를 표준정규로 매핑. 이상치/skew 모두에 강건. 학습 시 분위수 테이블을 저장.
- `none` — 비활성.
- 변환 대상은 학습 시 한 번만 결정된다. `|skew| > skew_threshold` 인 컬럼만 선택되며, 미선택 컬럼은 스코어링에서도 그대로 통과한다 (분포 일관성).
- 부스팅 트리는 단조 변환에 본질적으로 강건하지만, 선형/신경망 확장이나 분포 가정을 쓰는 진단에는 효과가 있다.

스케일링

전처리 3단계 (마지막). sklearn 의 스케일러를 pandas 입출력으로 감싼 얇은 래퍼.

```
preprocessing:
    scaling_method: standard          # standard | minmax | robust | none
```

- `standard` — `StandardScaler` (평균 0, 분산 1). 기본.
- `minmax` — `MinMaxScaler` ([0, 1]).
- `robust` — `RobustScaler` (median, IQR — 이상치에 강건).
- `none` — 비활성 (passthrough).

부스팅 트리만 쓰면 의미가 작지만, 선형/신경망 확장을 가정해 옵션으로 둔다. 학습 시 fit 된 스케일러는 artifact 에 저장되어 스코어링 시 동일 변환이 적용된다.

변수 선택 (Stability Selection)

전처리 직후, 모델 학습 직전에 적용되는 선택적 단계이다. 단일 fit 한 번의 우연성을 제거하기 위해, 학습 데이터에서 임의의 부분표본을 반복 추출해 **변수가 얼마나 일관되게 선택되는지(selection probability)** 를 측정하고, 임계값 이상으로 자주 선택된 변수만 최종 학습에 사용한다. Meinshausen & Bühlmann (2010) 의 절차를 따른다.

절차

1. **Stratified 부분표본 추출** — 학습 데이터에서 `subsample_ratio` 비율로 `n_subsamples` 번 부분표본을 뽑는다. 클래스 비율이 부분표본마다 유지된다 (sklearn `StratifiedShuffleSplit`).
2. **부분표본별 변수 선택** — `base_estimator` 로 부분표본 한 번당 변수 셋을 뽑는다 (자세한 동작은 아래).
3. **선택 빈도 누적** — 각 변수가 부분표본 몇 번에서 뽑혔는지 세서 빈도 (0.0 ~ 1.0) 를 계산한다.
4. **임계값 이상 채택** — `frequency ≥ threshold` 인 변수만 최종 채택. 부족하면 `min_selected fallback` 으로 frequency 상위 N개를 보충한다.

Base estimator

```
feature_selection:
    enabled: true
    base_estimator: lasso          # lasso | lgbm
    n_subsamples: 200             # 부분표본 추출 횟수
    subsample_ratio: 0.5          # 각 부분표본 크기 비율 (Meinshausen 권고 = 0.5)
    threshold: 0.6                # 채택 임계값 (보통 0.6~0.8)
    random_state: 42
    min_selected: 1               # threshold 이상이 부족할 때 fallback 상위 N개
```

```
# lasso 전용
lasso_C: 0.1                                # L1 규제 강도 (낮을수록 더 sparse)

# lgbm 전용
lgbm_top_k: 30                               # 부분표본당 gain 상위 K개 채택
lgbm_n_estimators: 100                       # 부분표본 학습용 LGBM 트리 수 (가볍게)
lgbm_learning_rate: 0.1
```

- **lasso (L1 로지스틱 회귀)** — 부분표본 단위 fit 후 **non-zero coefficient** 변수를 선택. 선형 신호에 강하고 빠르며 해석이 쉽다. 범주형 컬럼은 full-X 기준 **frequency encoding** 으로 1회 사전 변환해 부분표본 마다 재인코딩하는 비용·bias 를 피한다.
- **lgbm (LightGBM gain 중요도)** — 부분표본 단위 fit 후 gain 중요도 **상위 lgbm_top_k 개**(중요도 > 0 만) 를 선택. 비선형·상호작용을 포착하지만 부분표본당 fit 비용이 크다. 범주형은 pandas category dtype 으로 LightGBM native 처리.

선택 기준이 다르므로 두 base estimator 가 항상 같은 변수를 뽑지 않는다. 선형 효과는 lasso 가, 상호작용·비선형은 lgbm 이 더 잘 찾는 경향이다.

설정 가이드

- **n_subsamples** — 표준 100~500. 소규모(< 5k 행)면 50~100 도 충분, 큰 데이터·고차원이면 200+. 추정 분산은 $\sqrt{n}$ 으로 줄어든다.
- **subsample_ratio** — 원 논문 권고 0.5. 부분표본이 너무 크면 모든 표본이 비슷해져 선택이 안정화되지 않고, 너무 작으면 fit 자체가 불안정해진다.
- **threshold** — 0.6 보수적, 0.8 매우 보수적. false-positive 통제 수준의 trade-off. 비교적 적은 채택을 원하면 0.7~0.8.
- **min_selected** — threshold 이상 변수가 부족할 때 frequency 상위 N개로 fallback. 모델 입력이 비어 학습이 실패하는 사고를 막는다. 운영 안정성용 안전망이며 평소엔 거의 발동되지 않아야 한다 (발동 시 WARN 로그).
- **lasso_C** — LogisticRegression(C=...) 의 역규제 강도. **낮을수록 규제 강함 → 더 sparse**. 0.1 이 시작점, feature 가 많이 살아 남으면 0.01 로 조이고, 너무 잘려나가면 1.0 으로 푼다.
- **lgbm_top_k** — 부분표본당 채택 상한. 일반적으로 전체 feature 의 30~50%. 너무 크면 거의 모든 feature 가 한 번씩 뽑혀 threshold 이상이 폭증한다.

Fallback / 실패 처리

- 부분표본 한 개 fit 이 실패해도 warning 만 남기고 다음 부분표본으로 진행 (예: 극단적인 stratify 결과로 한 클래스가 비는 경우).
- 모든 부분표본이 실패하면 RuntimeError . base_estimator 설정 점검 필요.
- threshold 이상 변수가 min_selected 미만이면 frequency 상위 N개로 fallback 하고 fallback_used=True 가 메타데이터에 기록된다.

산출물

`SelectionResult` 에 다음이 담긴다:

- `selected_features` — 채택된 변수 목록 (입력 컬럼 순서 유지).
- `frequencies` — 모든 변수의 선택 빈도 (0.0 ~ 1.0).
- `n_subsamples` — 실제 사용된 부분표본 수 (실패 제외).
- `fallback_used` — fallback 발동 여부.

선택 결과는 artifact 메타데이터에 저장되어 **스코어링 시 동일 컬럼 셋으로 강제 적용**된다. HTML/PDF 리포트에는 변수별 selection frequency 막대와 채택/제외 라벨이 표기된다 (예: `examples/credit/` 리포트 7번 섹션 참고).

언제 켜고, 언제 끄나

- **켄다** — feature 수가 많고 일부가 noise 일 가능성이 있는 경우, 운영 안정성과 설명 가능성이 중요한 경우, 학습/스코어링 컬럼 셋을 명시적으로 줄이고 싶은 경우.
- **끈다 (enabled: false)** — 도메인 지식으로 이미 `features.csv` 가 정제됐고 feature 수가 적은 경우, 부스팅 트리 자체의 내장 selection 으로 충분하다고 판단되는 경우.

구현 메모

코드: `auto_ml/feature_selection/stability.py` 의 `StabilitySelector`. `fit_select(X, y)`
-> `SelectionResult` 가 핵심 entry. 주요 흐름:

1. **base_estimator** 별 사전 인코딩 1회 (`_encode_for_lasso` / `_prepare_for_lgbm`). `lasso` 는 범주형에 **full-X frequency encoding**, `lgbm` 은 `pandas category dtype` 으로 변환. 부분표본마다 재인코딩하지 않아 비용과 bias 를 줄인다.
2. `StratifiedShuffleSplit(n_splits=n_subsamples, train_size=subsample_ratio, random_state=...)` 으로 부분표본 인덱스 시퀀스를 생성. 각 인덱스에 대해 base 선택 함수 호출.
3. **부분표본 선택**:
4. `_lasso_select` — `LogisticRegression(solver="liblinear", C=lasso_C, penalty="l1", max_iter=200)`. `abs(coef) > 1e-8` 인 컬럼을 채택.
5. `_lgbm_select` — `LGBMClassifier(...)` fit, gain importance 상위 `lgbm_top_k` 개 중 `importance > 0` 만 채택.
6. **실패 처리** — 부분표본 단일 실패는 try/except 로 잡아 warning 후 continue. 모든 부분표본이 실패하면 `RuntimeError`.
7. **threshold + fallback** — `frequencies[f] = count[f] / n_done`.
`frequency ≥ threshold` 인 변수만 채택, 부족하면 빈도 상위 `min_selected` 개로 fallback 하고 `fallback_used=True` 가 메타에 기록된다.

모델 래퍼

`auto_ml/models/` 의 래퍼들은 모두 동일한 인터페이스 (`fit` / `predict_proba` / `feature_importance` / `shap_values`) 를 따른다.

모델	범주형 처리	early_stopping	Focal Loss
<code>LGBMModel</code>	<code>pandas category dtype</code> native	<code>callbacks=[early_stopping(rounds)]</code>	O
<code>XGBModel</code>	컬럼별 <code>LabelEncoder</code> (<code>_encoders</code> 보관)	생성자 인자 <code>early_stopping_rounds</code> (XGB 2.x sklearn API)	O
<code>CatBoostModel</code>	native (<code>cat_features</code> 인덱스 전달)	학습 인자 <code>early_stopping_rounds</code>	O (<code>PythonUser</code>)
<code>ElasticNetModel</code>	내부 <code>OneHotEncoder</code> (학습 시 <code>fit</code> → 스코어링 재사용, <code>handle_unknown="ignore"</code>)	해당 없음 (무시)	X
<code>EnsembleModel</code>	서브모델에 위임	해당 없음 (no-op)	X

모든 모델은 동일한 전처리 결과와 (활성 시) 변수 선택 채택 컬럼 셋을 공유한 채 학습된다. **테스트 데이터** `primary_metric` 점수가 가장 좋은 모델(양상을 포함)이 best 로 선정되어 artifact 에 저장된다.

Trainer 흐름

`auto_ml/models/trainer.py` 의 `Trainer` 가 모델별로 다음을 수행:

- (옵션) `HyperparameterOptimizer` 가 `Optuna TPE` 로 `tuning.cv_folds` OOF 평균 `primary_metric` 을 최대화하는 파라미터 탐색.
- 튜닝된(또는 `fixed_params` 만) 파라미터로 `training.cv_folds` `StratifiedKFold` OOF 평가. 각 fold 의 `best_iter` 평균이 리포트의 `best_iter (avg)` 로 표기됨.
- 학습 데이터 전체로 최종 `fit`.
- 테스트 데이터로 평가 → 모델별 `holdout` 점수 산출.

모든 개별 모델 학습 완료 후, `ensemble.enabled: true` 이고 활성화된 모델이 2개 이상이면 `EnsembleModel` 을 자동 생성해 `results["ensemble"]` 로 추가한다. OOF 예측은 서브모델 OOF 의 가중 평균(재학습 없음), test/train 예측은 `EnsembleModel.predict_proba()` 로 실시간 계산한다.

앙상블

개요

`ensemble.enabled: true` (기본값) 로 설정하면 개별 모델 학습 완료 직후 `EnsembleModel` 이 자동으로 생성된다.

```
ensemble:
  enabled: true
  strategy: weighted_average    # 현재 지원: weighted_average
```

가중치 산출

각 서브모델의 테스트 `primary_metric` 점수에 **비례**하는 소프트맥스 가중치를 사용한다:

```
weight[i] = score[i] / sum(score[j] for all j)
```

점수가 높은 모델이 앙상블에서 더 큰 영향을 미친다.

스코어링 시 동작

`EnsembleModel` 은 모든 서브모델 인스턴스를 내부에 보관한다. `best.joblib` 에 저장될 때 `cloudpickle` 이 전체 객체 그래프(서브모델 포함)를 직렬화하므로, `Scorer.from_artifact("best.joblib")` 한 번 호출로 앙상블 스코어링이 완전히 동작한다 — 개별 서브 `artifact` 가 함께 있지 않아도 된다.

SHAP

서브모델별 raw-margin SHAP 값의 가중 평균을 반환한다. 반환 `shape` 는 개별 모델과 동일하게 `(n, n_features + 1)` 을 유지해 `auto-ml-explain` 과 완전히 호환된다.

ElasticNet 모델

`sklearn LogisticRegression(solver='saga')` 기반 L1+L2 혼합 규제 선형 모델. 부스팅 트리가 놓치는 단순 선형 신호를 포착하거나, 해석 가능한 계수(coefficient) 가 필요한 도메인에서 유용하다. 기본값은 `enabled: false` (opt-in).

```
models:
  elasticnet:
    enabled: true
    fixed_params:
      max_iter: 2000
    search_space:
```



```
C: { type: float, low: 1.0e-3, high: 10.0, log: true }
l1_ratio: { type: float, low: 0.0, high: 1.0 }
```

- `C` — 역규제 강도. 낮을수록 규제 강함 (더 sparse 계수).
- `l1_ratio` — L1/L2 혼합 비율. 0.0 = 순수 L2 (Ridge), 1.0 = 순수 L1 (Lasso).
- **범주형 처리** — 내부 `OneHotEncoder` 로 자동 처리. `handle_unknown="ignore"` 로 스코어링 시 미학습 범주를 0-벡터로 안전하게 처리한다.
- **SHAP** — `shap.LinearExplainer` 를 사용한다. OHE 확장된 SHAP 값을 원본 피쳐 공간으로 합산해 반환하므로 `auto-ml-explain` 과 완전히 호환된다.
- **Focal Loss** — 미지원. `loss: logloss` (기본값) 만 사용 가능.
- `early_stopping_rounds` — 무시된다 (sklearn 에는 해당 개념이 없음).

손실 함수 (Focal Loss)

기본 손실은 라이브러리 native binary log-loss (`binary` / `binary:logistic` / `Logloss`) 이다. **클래스 불균형이 큰 데이터** (예: positive 비율 < 5%) 에서는 **Focal Loss** (Lin et al., 2017, ICCV) 가 잘 맞춘 쉬운 샘플의 손실을 $(1 - p_t)^\gamma$ 로 감쇠시켜 어려운 샘플에 학습 신호를 집중시킨다.

```
models:
  xgb:
    loss: focal                                # logloss (기본) | focal - 모델별 독립
    fixed_params:
      eval_metric: auc                        # AUC 는 rank-invariant → custom obj 와 호환
      tree_method: hist
      n_estimators: 2000
      focal_gamma: 2.0                        # easy-example 감쇠 지수 (기본 2.0)
      focal_alpha: 0.25                       # 양성 클래스 가중 (기본 0.25)
    search_space:
      # focal 하이퍼파라미터도 탐색 가능:
      # focal_gamma: { type: float, low: 0.5, high: 4.0 }
      # focal_alpha: { type: float, low: 0.1, high: 0.9 }
```

수식 (이진):

```
p = sigmoid(z), p_t = p if y=1 else 1-p, a_t = alpha if y=1 else 1-alpha
FL = -a_t * (1 - p_t)^gamma * log(p_t)
```

동작 / 호환성 메모

- `loss` 는 **모델별로 독립**. 한 모델만 focal 로 두고 나머지는 logloss 로 둘 수 있다.
- `ElasticNetModel` 과 `EnsembleModel` 은 Focal Loss 를 지원하지 않는다. 이 두 모델에는 `loss: logloss` (기본값) 만 지정해야 한다.

- `focal_gamma` / `focal_alpha` 는 `fixed_params` 에 두거나 `search_space` 로 탐색 가능 (예약 키 — 라이브러리 원본 파라미터에는 전달되지 않고 `wrapper` 가 pop).
- 내부 동작: `wrapper` 가 `objective` / `loss_function` 를 numpy 기반 callable (또는 CatBoost `PythonUserDefinedObjective` 클래스) 로 주입한다. LightGBM 의 경우 `predict_proba` 가 raw margin 을 반환하므로 `wrapper` 가 자체적으로 sigmoid 를 적용 (XGBoost / CatBoost 는 그대로 [0,1] 확률 반환). 외부 인터페이스 (`predict_proba` 가 1차원 [0,1] ndarray) 는 logloss 와 동일하다.
- 호환 가능한 `eval_metric` / `metric` 은 **순위 기반** 지표 (`auc` , `pr_auc` , `AUC`). 절대값 기반 지표 (`binary_logloss` , `Logloss` 문자열 등) 는 raw score 에 잘못 적용되어 의미가 깨지므로 사용하지 않는다.
- 폐쇄망 친화: 추가 의존성 없음. numpy + 기존 라이브러리만 사용. callable 은 모듈 최상위 함수 + `functools.partial` 패턴이라 joblib pickle 가능 — 스코어링 별도 프로세스에서 artifact 가 정상 복원된다.

구현: `auto_ml/models/losses.py` 에 `focal_grad_hess` , `lgb_focal_objective` , `xgb_focal_objective` , `CatBoostFocalObjective` 가 정의되어 있다. 세 `wrapper` 의 `_resolved_params()` 가 `self.loss == "focal"` 일 때 본 모듈의 객체를 주입한다.

하이퍼파라미터 최적화

각 모델 블록에 `fixed_params` (항상 적용) 와 `search_space` (Optuna 탐색 범위) 를 둔다. `tuning.enabled: true` 이고 모델별 `search_space` 가 비어있지 않으면 Optuna TPE 가 KFold OOF `primary_metric` 을 최대화하는 파라미터를 찾는다.

설정

```
training:
  cv_folds: 5                # 최종 OOF 평가용 fold 수
  random_state: 42
  early_stopping_rounds: 50  # 부스팅 모델 조기종료 라운드 수
  primary_metric: roc_auc    # 모델 선택 / 튜닝 목적함수

tuning:
  enabled: true
  n_trials: 30               # 모델당 시도 횟수
  timeout: null              # 초 단위 wall-clock 상한 (null 이면 제한 없음)
  cv_folds: 3                # 튜닝 단계 fold 수 (보통 training.cv_folds 보다 작
  random_state: 42           계)

models:
  lgbm:
    enabled: true
    fixed_params: { objective: binary, metric: auc, verbose: -1, n_estimators:
```

```
2000 }
    search_space:
      learning_rate: { type: float, low: 0.01, high: 0.3, log: true }
      num_leaves:    { type: int,   low: 15,   high: 255 }
      reg_lambda:    { type: float, low: 1.0e-8, high: 10.0, log: true }
```

search_space 형식

- `type: float` — `low`, `high`, `log` (선택, 기본 `false`).
- `type: int` — `low`, `high`, `log` (선택), `step` (선택, 기본 1).
- `type: categorical` — `choices: [...]`.

`search_space` 가 비어있으면 해당 모델은 `fixed_params` 만으로 학습한다 (튜닝 스킵).

primary_metric 지원 목록

`auto_ml/reporting/metrics.py:SUPPORTED_METRICS` 가 단일 진실 출처: `roc_auc` | `pr_auc` | `accuracy` | `precision` | `recall` | `f1` | `ks` | `lift`. 모두 **최대화** 방향이다. 도메인별 권장:

- `roc_auc` — 일반 (기본).
- `pr_auc` — `positive` 비율이 매우 낮은 불균형 데이터.
- `ks` — 신용평점 컨텍스트.
- `f1` / `precision` / `recall` — 임계값 0.5 기준이라 운영 임계값을 다르게 쓰는 경우엔 `roc_auc` / `pr_auc` 가 더 안전.

early_stopping

`training.early_stopping_rounds` 는 부스팅 모델 세 종류에 모두 적용되지만 내부 구현은 다르다 (위 모델 래퍼 표 참고). OOF 평가 단계의 `fold` 학습에는 적용되고 **최종 fit 에는 적용되지 않는다** (`early_stopping` 이 검증셋을 요구하므로).

과적합 완화 가이드

리포트 §3 "오버핏 점검" 의 $\Delta = \text{Train} - \text{Test}$ 가 큰 경우 (예: 주요 지표 기준 $|\Delta| \geq 0.05$), 다음 4축의 정규화 레버를 `search_space` 에 노출해 Optuna 가 자동으로 강도를 찾도록 한다. 기본 `configs/example.yaml` 와 `examples/credit/config.yaml` 에 이미 추가되어 있어 그대로 학습하면 적용된다.

4축 정규화 레버

축	LGBM	XGBoost	CatBoost
L1 (가중치 sparse 화)	<code>reg_alpha</code> (1e-8 ~ 10, log)	<code>reg_alpha</code> (1e-8 ~ 10, log)	— (CatBoost 는 L1 미지원)

축	LGBM	XGBoost	CatBoost
→ 변수 선택 효과)			
L2 (가중치 크기 제약)	<code>reg_lambda</code> (1e-8 ~ 10, log)	<code>reg_lambda</code> (1e-8 ~ 10, log)	<code>l2_leaf_reg</code> (1 ~ 100, log)
분할 보수성 (이득 임계값)	<code>min_gain_to_split</code> (0 ~ 0.5)	<code>gamma</code> (0 ~ 5)	— (depth 로 대체)
모델 native 노이즈	<code>feature_fraction</code> / <code>bagging_fraction</code> (0.6 ~ 1.0)	<code>subsample</code> / <code>colsample_bytree</code> (0.6 ~ 1.0)	<code>random_strength</code> (0 ~ 10) + <code>bagging_temperature</code> (0 ~ 1)

이미 노출된 트리 복잡도 레버 (`num_leaves`, `max_depth`, `depth`, `min_data_in_leaf`, `min_child_weight`) 와 함께 동시에 탐색된다.

△ 가 큰 경우 권장 대처 순서

1. `tuning.n_trials` 를 **30~50 으로 증가** — 위 레버 추가로 trial 당 탐색 효율이 떨어졌으므로 trial 수를 늘려 균형을 맞춘다. `credit/config` 기본 `n_trials=15` 는 학습 시간 절약용 — 정규화 효과를 제대로 평가하려면 30+ 필요.
2. **변수 수가 많으면** `feature_selection.enabled: true` **활성화** — feature 수가 200+ 이면 `stability selection` 으로 noise 변수를 사전 제거하는 것이 가중치 정규화보다 효과가 큰 경우가 많다 (특히 LGBM/XGB 에서 L1 의 변수 선택 효과를 더 직접적으로 강제).
3. **트리 복잡도 상한 축소** — `num_leaves` 상한 255 → 63, `max_depth` 상한 10 → 6 등으로 좁혀 모델 표현력 자체를 제한.
4. `training.early_stopping_rounds` 를 **30~50 으로 유지** — 너무 작으면 과보수 (`best_iter` 미달), 너무 크면 과적합 진입.

운영 메모

- CatBoost 는 L1 정규화를 지원하지 않으므로 `l2_leaf_reg` 범위를 log scale 1 ~ 100 으로 넓혀 더 강한 규제까지 시도 가능. CatBoost 의 내부 기본은 3 이라 하한 1.0 은 유지 (그 미만은 의미 없음).
- `random_strength` (CatBoost) 는 분할점 점수에 가우시안 노이즈를 더하는 정규화. 큰 값은 학습을 보수적으로 만들지만 수렴 속도도 늦춘다 → `iterations` / `early_stopping_rounds` 와 함께 균형.
- 본 가이드의 모든 항목은 코드 변경 없이 `models.<name>.search_space` YAML 편집만으로 즉시 적용된다. `tuning/space.py:sample_params` 가 임의 키를 처리.

최종 모델 학습 전략 (final_fit_strategy)

왜 필요한가

기본 동작(early_stop_on_test)은 최종 모델 fit 의 early-stopping 검증셋으로 테스트셋을 사용한다. 즉 최종 트리 수(best_iter)가 테스트셋에 맞춰 정해지고, best 모델 선정도 같은 테스트 점수로 이뤄진다. 그 결과 리포트 §3 의 holdout 점수와 $\Delta = \text{Train} - \text{Test}$ 가 낙관적으로 편향되어 실제 일반화 gap 을 과소평가한다.

이를 줄이기 위해, 학습 단계에서 테스트셋을 전혀 노출하지 않는 두 가지 선택적 전략을 제공한다. 기본값은 현행 동작이라 지정하지 않으면 동작이 바뀌지 않는다.

세 가지 전략

전략	동작	테스트 셋 노출	권장 상황
early_stop_on_test (기본)	학습 전체로 fit 하되 테스트셋을 early-stopping valid 로 사용	O (학습 신호로 노출)	현행 호환. 단일 데이터 셋 일관성을 우선할 때
iteration_capping	CV fold 들의 best_iter 를 집계해 트리 수를 고정하고, early stopping 없이 train 전체로 재학습	X	리포트 §3 오버핏 Δ 가 큰데 정직한 트리 수로 재학습하고 싶을 때
cv_bagging	최종 재학습 없이 CV 의 K 개 fold 모델을 균등 가중 앙상블로 묶어 최종 모델로 사용	X	분산이 크고 안정성을 원할 때. 재학습 비용도 절약

두 신규 전략은 학습 단계에서 테스트셋을 보지 않으므로 Δ 가 정직해진다 — 보통 현행보다 약간 커 보일 수 있는데, 이는 편향이 제거된 정상적인 현상이다.

설정

```
training:
  final_fit_strategy: early_stop_on_test # early_stop_on_test (기본) |
iteration_capping | cv_bagging
  iteration_cap_aggregation: mean # iteration_capping 일 때: mean |
median
  iteration_cap_headroom: 1.0 # iteration_capping 일 때: capped =
ceil(agg * headroom)
```

동작 / 호환성 메모

- **모델별 iteration 키 차이 자동 처리** — `iteration_capping` 은 LGBM/XGBoost 의 `n_estimators`, CatBoost 의 `iterations` 를 모델 래퍼의 `ITER_PARAM_NAME` 으로 자동 식별해 고정한다.
- **ElasticNet 문제** — 부스팅이 아니라 고정할 트리 수가 없으므로 `iteration_capping` 에서는 조용히 일반 `refit`(테스트셋 미노출)으로 동작한다.
- **cv_bagging + 앙상블** — `ensemble.enabled: true` 와 함께 켜면, 각 모델이 이미 fold 평균 (bagging)이 되므로 그 위의 점수 비례 앙상블은 **자동 비활성화**되고 WARN 로그가 남는다.
- **best_iter 미발동 fold** — early stopping 이 발동하지 않은 fold 는 `n_estimators / iterations` 설정값을 fallback 으로 사용해 집계가 0 방향으로 끌려가지 않게 한다.
- **artifact 자기기술** — 사용된 전략은 `artifacts/.../models/<name>.joblib` 메타데이터의 `extra.training_mode` 에 기록된다 (`iteration_capping` 은 `iteration_cap`, `cv_bagging` 은 `cv_bagging` 부가 정보 포함). `cv_bagging` 의 sub-artifact 는 K 개 fold 모델을 품은 `EnsembleModel` 1개라 그 자체로 `auto-ml-score` / `auto-ml-explain` 호환이다.

SHAP 해석 (auto-ml-explain)

학습된 모형이 각 입력 행을 왜 그렇게 예측했는지 **변별·변수별 기여도** 를 산출한다. LGBM/XGB/CatBoost 는 native API (`pred_contrib` / `ShapValues`) 를 사용하고, `ElasticNetModel` 은 `shap.LinearExplainer` 를 사용한다. `EnsembleModel` 은 서브모델 SHAP 의 가중 평균을 반환한다. 모든 모델의 `shap_values()` 는 `(n, n_features + 1)` 형태로 반환 — `Explainer` 와 완전 호환.

```
# 학습 후 같은 config 로 호출
auto-ml-explain --config configs/example.yaml
```

출력 스키마 (Wide)

```
<id_columns> + shap_<feature_1> + shap_<feature_2> + ... + base_value + score
```

- `base_value`: 모델의 평균 예측 확률 (각 행 동일).
- `shap_<feature>`: 해당 변수가 평균 대비 예측을 얼마나 끌어올렸/내렸는지 (확률 도메인).
- `score`: 최종 예측 확률 (= `Scorer.score` 와 동일).
- **가법성 보장**: 모든 행에서 `base_value + sum(shap_*) == score` (수치 오차 $\leq 1e-12$).

도메인 변환 공식

native API 는 raw-margin (logit) 도메인 SHAP 을 반환한다. 본 라이브러리는 다음과 같이 확률 도메인으로 변환하면서 가법성을 보존한다:

```
p_base = sigmoid(base_raw)
p_pred = sigmoid(base_raw + sum(feature_raw))
shap_prob[i] = feature_raw[i] / sum(feature_raw) * (p_pred - p_base)
```

비율은 raw 도메인 그대로 유지되고, 합산만 (score - base_value) 와 정확히 일치하도록 스케일링된다.

설정

```
explain:
  input_path:  ./data/score_input.parquet    # 스코어링 입력과 동일해도 무방
  output_path: ./artifacts/explanations/shap.parquet
  id_columns:
    - user_id                                # ScoringConfig 와 동일한 우선순위
```

id_columns 가 비어 있으면 top-level id_columns → artifact metadata 순으로 fallback.

설치

```
python -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
pip install -e .
```

WeasyPrint 는 시스템 폰트와 일부 라이브러리(libpango 등) 가 필요하다. 폐쇄망에서는 wheelhouse + 시스템 패키지를 함께 배포한다.

사용

```
# 1) 더미 데이터 생성 (검증용)
python examples/make_dummy_data.py

# 2) 학습 - 산출물:
#   artifacts/models/best.joblib
#   artifacts/reports/report.html, report.pdf
#   artifacts/predictions/test_predictions.parquet (id + score + prediction + target)
auto-ml-train --config configs/example.yaml

# 3) 스코어링 - 산출물:
#   artifacts/scores/scores.parquet (id_columns + score + prediction)
auto-ml-score --config configs/example.yaml
```

```
# 4) SHAP 해석 - 산출물:
#   artifacts/explanations/shap.parquet
#   (id_columns + shap_<feature>... + base_value + score, 확률 도메인)
auto-ml-explain --config configs/example.yaml
```

코드에서 직접 호출하는 예시는 `examples/run_train.py`, `examples/run_score.py` 참고.

모형 후보 관리 (Best 변경)

학습 시 모든 모형이 별도 sub-artifact 로 함께 저장된다:

<code>artifact_dir/best.joblib</code>	← 운영용 (scoring/explain 대상)
<code>artifact_dir/models/lgbm.joblib</code>	← 후보 1
<code>artifact_dir/models/xgb.joblib</code>	← 후보 2
<code>artifact_dir/models/catboost.joblib</code>	← 후보 3
<code>artifact_dir/models/elasticnet.joblib</code>	← 후보 4 (enabled: true 일 때)
<code>artifact_dir/models/ensemble.joblib</code>	← 앙상블 후보 (enabled: true 일 때)

`best.joblib` 은 위 sub-artifact 중 하나의 복사본이다. 기본은 `training.primary_metric` 기준 holdout 점수 최고 모형(앙상블 포함). 각 sub-artifact 는 독립 번들이라 그 자체로 `auto-ml-score` / `auto-ml-explain` 호환이다.

`ensemble.joblib` 은 모든 서브모델을 내부에 포함하므로, 이 파일 하나만으로 앙상블 스코어링이 완전히 동작한다.

학습 시점에 best 강제 지정

```
training:
  primary_metric: roc_auc
  best_model: lgbm          # null/생략 시 자동 선정. 지정 시 그 모형을 best 로.
                           # 가능한 값: lgbm | xgb | catboost | elasticnet |
ensemble
```

알 수 없는 모형 이름이면 학습이 명시적 `ValueError` 로 실패한다.

학습 후 best 교체 (재학습 없이)

```
auto-ml-set-best --config configs/example.yaml --model xgb
# artifact_dir/models/xgb.joblib → artifact_dir/best.joblib 로 복사.
# scoring / explain 이 즉시 새 모형 사용.
```



```
# 앙상블을 best 로 승격:
auto-ml-set-best --config configs/example.yaml --model ensemble
```

승격된 best 의 metadata.extra 에는 promoted_at / promoted_from (이전 best 모형명) 이 기록되어 운영 추적이 가능하다.

후보 모형의 상세 리포트

비-best 모형마다 별도 sub-report 가 자동 생성된다:

```
reporting.output_dir/sub/lgbm/report.html
reporting.output_dir/sub/lgbm/report.pdf
reporting.output_dir/sub/lgbm/feature_importance.csv
reporting.output_dir/sub/xgb/...
reporting.output_dir/sub/elasticnet/...
reporting.output_dir/sub/ensemble/...
```

각 sub-report 는 점수 표(현 모형 vs best), feature importance, decile/confusion/ score distribution, 변수 선택 결과, 학습 설정/튜닝 요약 을 담는다. 변수 선택 CSV(feature_selection.csv) 는 모형 무관이라 메인 리포트에만 1개 둔다.

타이타닉 end-to-end 예시

실제 공개 데이터셋(Titanic, 891 rows) 으로 전체 파이프라인을 검증할 수 있다.

```
# 데이터 준비 (GitHub 에서 1회 다운로드 → data/titanic/
{train,test,score_input}.parquet)
python examples/titanic/prepare_data.py

# 학습 - 산출물: artifacts/titanic/{models,reports,logs}/...
auto-ml-train --config examples/titanic/config.yaml

# 스코어링 - 산출물: artifacts/titanic/scores/scores.parquet
auto-ml-score --config examples/titanic/config.yaml
```

검증 시 약 10초 내외 (Optuna 10 trials × 3 모델 × 3 fold) 에 best 모델 ROC-AUC ≈ 0.86 을 재현한다. 폐쇄망에서는 TITANIC_CSV 환경변수에 사전 배포한 CSV 경로를 지정하면 prepare_data.py 가 네트워크 없이 동일 산출물을 만든다.

폐쇄망 이관

다음 4가지만 옮기면 된다:

1. 패키지 wheel (pip wheel -r requirements.txt -w wheelhouse/)

2. 본 repo 자체 (또는 `pip install -e .` 으로 wheel 생성)
3. 학습 산출물 `artifacts/models/best.joblib`
4. 스코어링 설정 YAML

설정

전체 옵션은 `configs/example.yaml` 참고. 모든 키는 `auto_ml/config.py` 의 `dataclass` 와 1:1 대응한다.

작업 로그

실행마다 `stage( train / score )` 별 별도 로그 파일이 자동 생성된다.

```
artifacts/logs/  
├─ train_20260425_143052.log  
└─ score_20260425_180001.log
```

설정 (`configs/example.yaml` 의 `logging` 섹션):

```
logging:  
  log_dir: ./artifacts/logs  
  level: INFO          # DEBUG | INFO | WARNING | ERROR  
  to_stdout: true  
  to_file: true
```

콘솔 출력과 파일 출력은 동시에 활성화 가능하며, `to_file: false` 로 두면 파일은 만들지 않는다. 각 로그는 시작/종료 마커, 단계별 진행, 모델 튜닝 결과, 산출물 경로, 총 소요 시간을 포함한다.

운영 메모

- 타깃은 0/1 만 허용 (`utils/validation.py` 가 검증).
- `best` 선정은 테스트 데이터 점수 기준. 기본 학습 전략은 최종 fit 의 `early-stopping` 에도 테스트셋을 쓰므로 `holdout/Δ` 가 낙관적으로 편향될 수 있다 — `training.final_fit_strategy` 를 `iteration_capping` / `cv_bagging` 으로 바꾸면 학습 단계에서 테스트셋을 노출하지 않는다 (자세한 내용은 "## 최종 모델 학습 전략" 절 참고).
- 손실 함수 기본은 `binary logloss`. `models.<name>.loss: focal` 로 모델별 Focal Loss 전환 가능 (`focal_gamma=2.0` , `focal_alpha=0.25` 기본). 자세한 내용은 "## 손실 함수" 절 참고.
- 학습 시 사용한 `features` 정의가 `artifact` 메타데이터에 저장되어 스코어링 시 동일 컬럼 셋·동일 전처리·동일 모델로 처리된다.
- 스코어링 결과 컬럼: `<id_columns> + score + prediction`.

- 학습 시 best 모델의 holdout 예측을 함께 내보낸다 — `<artifact_dir>/../predictions/test_predictions.parquet`, 스키마 `<id_columns> + score + prediction + <target_column>`. 외부 BI / 추가 진단용 (overfit 검증, 임계값 튜닝 등).
- 학습 데이터에서 어떤 수치형 컬럼이 전부 NaN 이면 결측·이상치 단계가 명시적 `ValueError` 로 실패한다 (silent NaN 전파 방지). `features.csv` 의 `used` 를 `false` 로 두거나 해당 단계를 비활성화/`constant` 전략으로 전환.