

auto_ml 사용 설명서

이 문서는 두 파트로 구성됩니다.

- Part I. 튜토리얼 (§1–5) — 처음 사용하는 분이 설치부터 첫 실행까지 따라할 수 있는 단계별 안내.
- Part II. 레퍼런스 (§6–18) — 설정 파일의 모든 섹션을 모듈별로 정리. 각 섹션은 역할 → 옵션 표 → YAML 예시 → 동작 메모 4단으로 반복되어, 필요한 부분만 찾아 읽도록 설계되었습니다.

새 기능 — 최종 모델 학습 전략 (**final_fit_strategy**): 테스트셋 누설 없이 오버핏(Train-Test Δ)을 줄이는 `iteration_capping` / `cv_bagging` 옵션이 추가되었습니다. → [§11 최종 모델 학습 전략](#)

목차

Part I. 튜토리얼

1. 라이브러리 소개
2. 전체 흐름
3. 사전 준비
4. 설치
5. 빠른 시작

Part II. 설정 레퍼런스

1. 설정 파일 구조와 YAML 문법
2. 데이터 입력 (top-level)
3. `features.csv` — 사용할 컬럼 정의
4. 전처리 `preprocessing`
5. 변수 선택 `feature_selection`
6. 학습 `training`
 - ↳ 최종 모델 학습 전략 — `iteration_capping` / `cv_bagging`
7. 튜닝 `tuning`
8. 모델 `models`
9. 앙상블 `ensemble`
10. 리포트 `reporting`
11. 스코어링 `scoring`
12. SHAP 해석 `explain`
13. 로깅 `logging`

부록

- [A. CLI 명령어 모음](#)
- [B. 산출물 안내](#)
- [C. 트러블슈팅 FAQ](#)
- [D. 폐쇄망 이관](#)
- [E. 용어 사전](#)

Part I. 튜토리얼

1. 라이브러리 소개


`auto_ml` 은 이진 분류(0/1) 문제를 자동으로 학습·스코어링하는 사내 라이브러리입니다. 이탈/비이탈, 사기/정상, 구매/비구매 같은 "예/아니오" 답을 맞히는 모든 문제에 쓸 수 있습니다.

ML 코드를 직접 작성할 필요는 없습니다. YAML 설정 한 개와 컬럼 정의 CSV 한 개만 준비하면 라이브러리가 다음을 수행합니다.

- 결측치 채우기, 이상치 원저라이징, skew 변환, 스케일링
- (선택) Stability Selection 으로 변수 자동 선별
- LightGBM / XGBoost / CatBoost / ElasticNet 네 가지 모델 학습
- Optuna 로 하이퍼파라미터 베이지안 탐색
- 모델들을 가중 평균 앙상블로 자동 결합
- 테스트 점수 기준 best 모델 선정
- HTML / PDF 리포트 생성
- 학습 결과 한 덩어리(`best.joblib`)로 저장

학습이 끝나면 **auto-ml-score** 한 줄로 새 데이터에 점수를 매길 수 있습니다(cron 등 배치 운영용).

2. 전체 흐름



핵심 명령어는 두 개입니다.

명령어	언제 쓰나	결과물
<code>auto-ml-train</code>	모델을 만들 때 (보통 주 1회)	<code>best.joblib</code> , HTML/PDF 리포트, 로그
<code>auto-ml-score</code>	새 데이터에 점수를 매길 때 (반복)	<code>scores.parquet</code>

추가 명령어: - `auto-ml-explain` — SHAP 으로 건별 변수 기여도 산출. - `auto-ml-set-best` — 학습 후 best 모델을 다른 후보로 교체(재학습 불필요).

3. 사전 준비

필요한 것

- Python 3.9 이상 (`python --version` 으로 확인)
- pip (보통 Python 과 함께 설치)
- Git (소스 코드 clone 용)
- (PDF 리포트를 만들려면) WeasyPrint 시스템 의존성
- macOS: `brew install pango libffi`
- Ubuntu/Debian: `sudo apt-get install libpango-1.0-0 libpangoft2-1.0-0`
- 미설치 시 학습/스코어링은 정상 동작하고 HTML 리포트만 생성됩니다.

디스크 / 메모리

- 더미 예제 기준 디스크 500MB 면 충분.
- 학습 데이터가 수백만 행이면 메모리 8GB 이상 권장.

4. 설치

터미널에서 한 줄씩 차례대로 실행합니다.

```
# 1) 프로젝트 폴더로 이동
cd auto-ml-briefly

# 2) 가상환경 생성 (시스템 Python 을 더럽히지 않도록)
python -m venv .venv

# 3) 가상환경 활성화
source .venv/bin/activate          # macOS / Linux
.venv\Scripts\Activate.ps1        # Windows (PowerShell)

# 4) 의존성 설치
pip install -r requirements.txt
```

```
# 5) auto_ml 자체를 editable 모드로 설치 (CLI 명령 활성화)
pip install -e .
```

설치를 확인합니다.

```
auto-ml-train --help
auto-ml-score --help
```

도움말이 나오면 성공입니다. `command not found` 가 보이면 가상환경 활성화 여부를 다시 확인하세요(프롬프트 앞에 `(.venv)` 가 보여야 합니다).

5. 빠른 시작

진짜 데이터를 준비하기 전에, 더미 데이터로 동작 여부를 한 번 확인합니다.

```
# 1) 더미 데이터 생성 - data/ 에 train/test/score_input parquet 생성
python examples/make_dummy_data.py

# 2) 학습
auto-ml-train --config configs/example.yaml

# 3) 스코어링
auto-ml-score --config configs/example.yaml
```

산출물은 다음 구조로 만들어집니다.

```
artifacts/
├─ models/
│   └─ best.joblib          ← 전처리 + 모델 + 메타데이터 한 덩어리
├─ reports/
│   ├── report.html        ← 브라우저로 열기
│   └─ report.pdf          ← 동일 내용 PDF
├─ scores/
│   └─ scores.parquet      ← id_columns + score + prediction
└─ logs/
    ├── train_YYYYMMDD_HHMMSS.log
    └─ score_YYYYMMDD_HHMMSS.log
```

`artifacts/reports/report.html` 을 브라우저로 열어 모델 비교표, ROC 곡선, feature importance 등이 표시되면 설치가 정상입니다. 다음 단계는 본인 데이터로 같은 흐름을 돌리는 것입니다 — 필요한 설정은 Part II 에서 섹션별로 찾아보면 됩니다.

자기 데이터로 돌릴 때 보통 손대는 곳은 세 군데입니다.

1. `configs/example.yaml` 을 복사해 데이터 경로·타겟 컬럼 이름만 수정 → §7 데이터 입력
2. `configs/features.csv` 에 사용할 컬럼을 적기 → §8 `features.csv`
3. 필요에 따라 모델·튜닝·앙상블 설정 조정 → §13 모델, §12 튜닝, §14 앙상블

Part II. 설정 레퍼런스

6. 설정 파일 구조와 YAML 문법

6.1 파일 구조

설정 YAML 은 다음 최상위 키들로 구성됩니다. 모든 키는 선택이며, 누락 시 기본값이 적용됩니다(코드의 `auto_ml/config.py` `dataclass` 와 1:1 대응).

```
# ----- top-level (데이터 입력) -----
train_data_path: ./data/train.parquet      # §7
test_data_path:  ./data/test.parquet
target_column:   target
features_csv:    ./configs/features.csv
id_columns:      [user_id]
artifact_dir:    ./artifacts/models

# ----- 하위 섹션 -----
preprocessing:   {...}      # §9
feature_selection: {...}    # §10
training:        {...}      # §11
tuning:          {...}      # §12
models:          {...}      # §13
ensemble:        {...}      # §14
reporting:       {...}      # §15
scoring:         {...}      # §16
explain:         {...}      # §17
logging:         {...}      # §18
```

전체 옵션을 한눈에 보고 싶다면 `configs/example.yaml` 을 참고하세요 — 모든 기본값이 주석과 함께 노출되어 있어 그대로 복사·수정해서 쓸 수 있습니다.

6.2 YAML 문법 빠른 참고

```
# 1) 스칼라
key: value          # 문자열·숫자·boolean
```

```

flag: true          # boolean: true/false
n: 5                # int
ratio: 0.5          # float
maybe: null        # 명시적 null

# 2) 리스트 (블록 / 인라인)
items:
  - a
  - b
items_inline: [a, b] # 동일

# 3) 매핑 (중첩)
training:
  cv_folds: 5
  primary_metric: roc_auc

# 4) 인라인 dict - search_space 처럼 한 줄에 여러 키
learning_rate: { type: float, low: 0.01, high: 0.3, log: true }

# 5) 들여쓰기는 항상 공백 2칸 (탭 금지)
# 6) 주석은 #
# 7) 문자열 따옴표는 생략 가능하나 특수문자 포함 시 권장
title: "Credit Default Auto-ML Report"

```

YAML 작성 시 흔히 겪는 함정:

- 탭 들여쓰기 금지 — 모든 들여쓰기는 공백. 에디터 설정에서 "Insert spaces" 켜두기.
- 불리언 표기 — `True` / `False` 도 동작하지만, 표준은 소문자 `true` / `false`.
- `null` 과 빈 문자열 — `key: null` (값 없음) 과 `key: ""` (빈 문자열) 은 다릅니다.
- 상대경로 기준 — 본 라이브러리의 모든 경로는 현재 작업 디렉토리(CWD) 기준입니다. 보통 프로젝트 루트에서 실행하세요.

7. 데이터 입력 (top-level)

역할

학습/테스트 데이터의 위치, 타깃 컬럼 이름, 결과에 보존할 식별자를 지정합니다. 본 라이브러리는 학습 데이터를 자동으로 train/test 분할하지 않습니다 — 사용자가 별도 Parquet 두 개로 준비해야 합니다.

옵션

키	타입	기본값	설명
<code>train_data_path</code>	str		학습 데이터 Parquet 경로

키	타입	기본값	설명
		<code>./data/train.parquet</code>	
<code>test_data_path</code>	str	<code>./data/test.parquet</code>	테스트 데이터 Parquet 경로 (별도 파일)
<code>target_column</code>	str	<code>target</code>	타겟 컬럼 이름. 값은 0/1 만 허용 (다른 값 섞이면 <code>ValueError</code>)
<code>features_csv</code>	str	<code>./configs/features.csv</code>	사용할 컬럼 정의 CSV 경로. 빈 문자열 "" 이면 CSV 무시(코드에서 직접 <code>features</code> 지정)
<code>id_columns</code>	list[str]	<code>[]</code>	결과(스코어링/SHAP)에 그대로 보존할 식별자 컬럼 목록
<code>artifact_dir</code>	str	<code>./artifacts/models</code>	<code>best.joblib</code> 과 sub-artifact 가 저장될 디렉토리

YAML 예시

```
train_data_path: ./data/my_train.parquet
test_data_path:  ./data/my_test.parquet
target_column:   churn
features_csv:    ./configs/my_features.csv
id_columns:
  - user_id
artifact_dir:    ./artifacts/models
```

동작 메모

- 타겟은 0/1 만 허용 — `utils/validation.py` 가 검증합니다. 결측·문자열·2 이상의 정수 등이 섞여 있으면 즉시 실패합니다.
- 컬럼 일관성 — 학습/테스트/스코어링 입력에 같은 컬럼 셋이 있어야 합니다. 학습 시 사용된 features 정의는 artifact 메타데이터에 박혀 스코어링 시 검증됩니다(빠진 컬럼은 명시적 에러).
- `id_columns` 는 top-level 에서 한 번만 적어두면 `scoring.id_columns` / `explain.id_columns` 가 비어 있을 때 자동 fallback 됩니다.

8. features.csv — 사용할 컬럼 정의

역할

데이터의 어떤 컬럼을 어떤 타입으로 학습에 쓸지 명시하는 명단입니다. 운영 중 변수를 켜고 끌 때 코드를 고치지 않고 이 CSV 만 수정하면 됩니다.

CSV 형식

컬럼	의미	허용 값
name	Parquet 의 컬럼명과 정확히 일치	(Parquet 컬럼명)
type	컬럼 종류	continuous (수치형) / category (범주형)
used	학습/스코어링 사용 여부	true / false (대소문자 무시, 1 / 0 , yes / no 도 허용)

예시

```
name,type,used
age,continuous,true
gender,category,true
income,continuous,true
internal_score,continuous,false
```

동작 메모

- 타겟 컬럼·id 컬럼은 적지 않습니다. 각각 `target_column` / `id_columns` 로 따로 지정합니다.
- `used: false` 인 행은 학습/스코어링에 포함되지 않습니다 (CSV 에 남겨두기만 해도 무방).
- 빈 행은 조용히 건너뜁니다. 같은 `name` 이 두 번 나오면 `ValueError`.
- 결과적으로 `used == true` 인 행이 하나도 없으면 `ValueError` (학습할 컬럼이 없음).

9. 전처리 preprocessing

역할

전처리는 항상 다음 순서로 적용됩니다.

(1) 결측 처리 → (2) 이상치 처리 → (2.5) skew 변환 → (3) 스케일링

학습 시 산출된 통계량(중앙값, 분위수 경계, 분위수 테이블, 스케일러 fit 결과)은 모두 `best.joblib` 에 저장되어 스코어링 시 그대로 재적용됩니다 — 학습/스코어링 일관성이 자동 보장됩니다.

옵션

키	타입	기본값	허용 값	설명
<code>numeric_null_strategy</code>	str	<code>median</code>	<code>median</code> / <code>mean</code> / <code>constant</code>	수치형 결측 채움 전략
<code>numeric_null_fill_value</code>	float	<code>0.0</code>	—	<code>constant</code> 일 때 채움 값
<code>categorical_null_strategy</code>	str	<code>most_frequent</code>	<code>most_frequent</code> / <code>constant</code>	범주형 결측 채움 전략
<code>categorical_null_fill_value</code>	str	<code>MISSING</code>	—	<code>constant</code> 일 때 채움 값
<code>outlier_method</code>	str	<code>percentile</code>	<code>percentile</code> / <code>none</code>	이상치 처리 방식
<code>outlier_lower_quantile</code>	float	<code>0.01</code>	<code>[0, 1)</code>	원저라이징 하한 분위수
<code>outlier_upper_quantile</code>	float	<code>0.99</code>	<code>(0, 1]</code>	원저라이징 상한 분위수
<code>outlier_action</code>	str	<code>clip</code>	<code>clip</code> / <code>null_then_impute</code>	경계 밖 값 처리 방식
<code>skew_method</code>	str	<code>signed_loglp</code>	<code>signed_loglp</code> / <code>quantile_normal</code> / <code>none</code>	skew 변환 방식
<code>skew_threshold</code>	float	<code>1.0</code>	—	<code> skew > threshold</code> 인 컬럼만 변환
<code>scaling_method</code>	str	<code>standard</code>	<code>standard</code> / <code>minmax</code> / <code>robust</code> / <code>none</code>	스케일링 방식

YAML 예시

```
preprocessing:
  numeric_null_strategy: median          # median | mean | constant
  numeric_null_fill_value: 0.0
```

```

categorical_null_strategy: most_frequent      # most_frequent | constant
categorical_null_fill_value: MISSING

outlier_method: percentile                    # percentile | none
outlier_lower_quantile: 0.01
outlier_upper_quantile: 0.99
outlier_action: clip                          # clip | null_then_impute

skew_method: signed_log1p
# signed_log1p | quantile_normal | none
skew_threshold: 1.0

scaling_method: standard                     # standard | minmax | robust |
none

```

동작 메모

결측 처리 - 전부-NaN 가드: 학습 데이터에서 어떤 수치형 컬럼이 전부 NaN 이면 `median / mean` 계산이 불가능해 silent 전파를 막기 위해 `ValueError` 로 실패합니다. `features.csv` 에서 해당 컬럼을 `used: false` 로 두거나 `constant` 전략으로 전환하세요. - 스코어링 시 컬럼 자체가 통째로 누락된 경우에도 학습 시점의 기본값(수치형 median, 범주형 최빈값)으로 자동 채워집니다 — 일시 누락에 대한 안전망.

이상치 처리 - `clip` (기본): 경계 밖 값을 경계로 잘라냅니다. - `null_then_impute`: 경계 밖을 NaN 으로 바꾼 뒤 median 으로 다시 채웁니다. - `lower < upper` 위반 시 `ValueError`.

Skew 변환 - 변환 대상은 학습 시 한 번 결정됩니다 (`|skew| > skew_threshold` 인 컬럼). 미선택 컬럼은 스코어링에서도 통과하여 분포 일관성이 유지됩니다. - `signed_log1p`: `sign(x) * log1p(|x|)`. 무상태(추가 저장 없음), 음수 보존. - `quantile_normal`: 학습 분포의 분위수를 표준정규로 매핑. 이상치/skew 모두에 강건하지만 분위수 테이블이 artifact 에 저장됩니다(크기 약간 증가). - 부스팅 트리만 쓰면 효과가 작으므로 `none` 으로 꺼도 무방합니다.

스케일링 - 부스팅 트리는 스케일링에 본질적으로 무관합니다. 옵션을 두는 이유는 선형/신경망 모델 확장을 대비함이며, 트리만 쓴다면 `none` 으로 뒀도 됩니다.

10. 변수 선택 `feature_selection`

역할

학습 데이터의 부분표본을 여러 번 뽑아 각 부분표본에서 변수를 골라 보고, 자주 선택되는 변수만 최종 채택합니다 (Meinshausen & Bühlmann, 2010 의 Stability Selection). 단일 fit 한 번의 우연성을 제거해 noise 변수가 채택되는 위험을 줄입니다.

기본값은 `enabled: false` — 변수가 적으면 (예: < 30개) 부스팅 모델 내장 selection 으로 충분하므로 굳이 켜지 않아도 됩니다.

옵션

키	타입	기본값	허용 값	설명
<code>enabled</code>	bool	<code>false</code>	—	사용 여부
<code>base_estimator</code>	str	<code>lasso</code>	<code>lasso / lgbm</code>	부분표본 단위 선택기
<code>n_subsamples</code>	int	<code>200</code>	—	부분표본 추출 횟수
<code>subsample_ratio</code>	float	<code>0.5</code>	<code>(0, 1)</code>	부분표본 크기 비율
<code>threshold</code>	float	<code>0.6</code>	<code>[0, 1]</code>	채택 임계값 (선택 빈도)
<code>random_state</code>	int	<code>42</code>	—	재현성 시드
<code>min_selected</code>	int	<code>1</code>	—	임계값 미달 시 빈도 상위 N 개 fallback
<code>lasso_C</code>	float	<code>0.1</code>	—	(lasso 전용) L1 규제 강도
<code>lgbm_top_k</code>	int	<code>30</code>	—	(lgbm 전용) 부분표본당 gain 상위 K
<code>lgbm_n_estimators</code>	int	<code>100</code>	—	(lgbm 전용) 부분표본 학습용 트리 수
<code>lgbm_learning_rate</code>	float	<code>0.1</code>	—	(lgbm 전용) 부분표본 학습률

YAML 예시

```
feature_selection:
  enabled: true
  base_estimator: lasso
  n_subsamples: 200
  subsample_ratio: 0.5
  threshold: 0.6
  random_state: 42
  min_selected: 3

# base_estimator: lasso 일 때만 사용
lasso_C: 0.1

# base_estimator: lgbm 일 때만 사용
lgbm_top_k: 30
lgbm_n_estimators: 100
lgbm_learning_rate: 0.1
```

동작 메모

`base_estimator` 선택 기준 비교

항목	<code>lasso</code> (L1 로지스틱)	<code>lgbm</code> (LightGBM gain)
선택 기준	non-zero coefficient	gain 상위 K (>0 만)
잘 잡는 신호	선형 효과	비선형 · 상호작용
범주형 처리	full-X frequency encoding (사전 1회)	pandas <code>category</code> dtype native
부분표본당 속도	빠름	상대적으로 느림

설정 가이드 - `n_subsamples` — 표준 100~500. 작은 데이터면 50~100 도 충분, 큰 데이터·고차원이면 200+. - `subsample_ratio` — 원 논문 권고 0.5. 너무 크면 모든 부분표본이 비슷해져 안정화 안 됨, 너무 작으면 fit 자체가 흔들림. - `threshold` — 0.6 보수적, 0.8 매우 보수적. false-positive 통제 강도의 trade-off. - `min_selected` — 채택이 부족할 때 발동하는 안전망. 평소엔 발동되지 않아야 하고, 발동 시 WARN 로그가 납니다. - `lasso_C` — 낮을수록 규제 강함(더 sparse). 0.1 시작, 변수가 너무 많 이 살면 0.01, 너무 잘려나가면 1.0. - `lgbm_top_k` — 전체 feature 의 30~50% 정도가 적당. 너무 크면 threshold 통과 변수가 폭증.

산출물 - 채택된 변수 목록·선택 빈도·fallback 발동 여부가 `SelectionResult` 로 `best.joblib` 메타데이터에 저장됩니다. - 스코어링 시 동일 컬럼 셋만 모델로 흘러갑니다 — 일관성 자동 보장. - HTML/PDF 리포트에 변수별 빈도 막대와 채택/제외 라벨이 표기됩니다.

11. 학습 `training`

역할

CV 폴드 수, 조기 종료 라운드, 모델 선택 지표, [최종 모델 학습 전략](#) 을 결정합니다. 파이프라인은 각 모델에 대해 (1) 튜닝 → (2) StratifiedKFold OOF 평가 → (3) 최종 fit → (4) 테스트 평가의 순서로 동작하며, best 모델은 테스트 점수 기준으로 자동 선정됩니다.

옵션

키	타입	기본값	허용 값	설명
<code>cv_folds</code>	int	5	—	최종 OOF 평가용 StratifiedKFold 분할 수
<code>random_state</code>	int	42	—	

키	타입	기본값	허용 값	설명
				폴드 분할 등 재현성 시드
<code>early_stopping_rounds</code>	int	50	—	부스팅 모델 조기 종료 라운드 수
<code>primary_metric</code>	str	roc_auc	roc_auc / pr_auc / ks / f1 / accuracy / precision / recall / lift	모델 선택·튜닝 목적함수
<code>best_model</code>	str / null	null	null / lgbm / xgb / catboost / elasticnet / ensemble	best 강제 지정 (null = 자동)
<code>final_fit_strategy</code>	str	early_stop_on_test	early_stop_on_test / iteration_capping / cv_bagging	최종 모델 학습 방식
<code>iteration_cap_aggregation</code>	str	mean	mean / median	(capping 전용) fold best_iter 집계 방식
<code>iteration_cap_headroom</code>	float	1.0	> 0	(capping 전용) 집계값 × headroom 후 ceil

`primary_metric` 가이드:

지표	추천 도메인
roc_auc	일반 (기본)
pr_auc	positive 비율이 매우 낮은 불균형 데이터
ks	신용평점 / 리스크 모델링
f1 / precision / recall	임계값 0.5 기준 평가
lift	상위 분위 lift

YAML 예시 (기본 옵션)

```
training:
  cv_folds: 5
  random_state: 42
  early_stopping_rounds: 50
  primary_metric: roc_auc
  best_model: null
```

최종 모델 학습 전략(`final_fit_strategy` / `iteration_cap_*`)은 옵션이 많아 아래 [최종 모델 학습 전략](#) 서브섹션에서 따로 다룹니다.

동작 메모

`early_stopping_rounds` 는 부스팅 세 모델에 통합 적용되지만 내부 구현이 다릅니다 (LGBM callbacks, XGB 생성자 인자, CatBoost 학습 인자). OOF fold 학습에는 항상 적용되지만, 최종 fit 의 적용 여부는 `final_fit_strategy` 에 좌우됩니다 (아래 서브섹션 참고).

`best_model` 강제 지정 - `lgbm` / `xgb` / `catboost` / `elasticnet` / `ensemble` 중 하나로 지정 가능. 알 수 없는 이름이면 `ValueError` . - 학습 후 변경하려면 `auto-ml-set-best --model <name>` CLI 사용 (재학습 불필요).

최종 모델 학습 전략 (`final_fit_strategy`)

`final_fit_strategy` 는 OOF 평가가 끝난 뒤 운영에 쓸 최종 모델을 어떻게 만들지를 결정합니다. 세 가지 중 하나를 고르며, 기본값은 현행 동작과 동일한 `early_stop_on_test` 입니다 — 지정하지 않으면 동작이 바뀌지 않습니다.

왜 필요한가

기본 `early_stop_on_test` 는 최종 모델을 학습할 때 테스트셋을 early-stopping 검증셋으로 사용합니다. 편리하지만 최종 트리 수(`best_iter`)와 best 모델 선정이 테스트셋에 맞춰지므로, 리포트 §3 "오버핏 점검" 의 $\Delta = \text{Train} - \text{Test}$ 가 실제보다 작게(낙관적으로) 나옵니다 — 즉 테스트 점수가 약간 부풀려집니다. 아래 두 전략은 학습 단계에서 테스트셋을 전혀 보지 않아 Δ 가 정직해집니다.

세 전략 비교

전략	동작	테스트 셋 노 출	언제 쓰나
<code>early_stop_on_test</code> (기본)	학습 전체로 fit, 테스트셋을 조기종료 검증셋으로 사용	0	현행 호환 / 단일 데이터셋 일관성 우선

전략	동작	테스트 셋 노 출	언제 쓰나
<code>iteration_capping</code>	CV fold best_iter 집계로 트리 수 고정, early stop 없이 train 전체로 재학습	X	오버핏 Δ 가 큰데 정직한 트리 수로 재학습하고 싶을 때
<code>cv_bagging</code>	최종 재학습 생략, CV 의 K fold 모델을 균등 가중 앙상블로 사용	X	분산을 줄이고 안정적인 모델을 원할 때 (재학습 비용도 절약)

관련 옵션 (모두 `training:` 아래):

키	적용 전략	설명
<code>final_fit_strategy</code>	공통	<code>early_stop_on_test</code> (기본) / <code>iteration_capping</code> / <code>cv_bagging</code>
<code>iteration_cap_aggregation</code>	<code>iteration_capping</code>	fold best_iter 집계 방식. <code>mean</code> (기본) / <code>median</code>
<code>iteration_cap_headroom</code>	<code>iteration_capping</code>	집계값에 곱하는 여유 배수. <code>capped = ceil(agg × headroom)</code> . 기본 1.0

YAML 예시

오버핏 Δ 가 큰 경우 — 정직한 트리 수로 재학습:

```
training:
  cv_folds: 5
  primary_metric: roc_auc
  final_fit_strategy: iteration_capping
  iteration_cap_aggregation: mean      # 각 fold best_iter 의 평균 (median 도 가능)
  iteration_cap_headroom: 1.0
# 1.0 = 평균 그대로. 1.05~1.1 로 올리면 약간 더 학습
```

안정적인 앙상블 — CV fold K 개 모델을 균등 평균:

```
training:
  final_fit_strategy: cv_bagging
```

동작 메모

- 두 신규 전략은 학습 단계에서 테스트셋을 보지 않으므로 리포트 §3 의 Δ 가 정직해집니다 (기본 전략보다 약간 커 보일 수 있는데, 편향이 제거된 정상 수치입니다).
- ElasticNet 은 **`iteration_capping`** 에서 자동 면제 (부스팅이 아니라 고정할 트리 수가 없음). 일반 refit 으로 동작하며 INFO 로그가 남습니다.

- `cv_bagging` 과 `ensemble.enabled: true` 를 함께 켜면 외부 앙상블이 자동 비활성화되고 WARN 로그가 남습니다 (각 모델이 이미 fold 평균 = bagging 이므로 중복 방지).
- 사용된 전략은 `<artifact_dir>/models/<name>.joblib` 메타데이터의 `extra.training_mode` 에 기록됩니다.

12. 튜닝 `tuning`

역할

Optuna TPE 샘플러로 각 모델의 `search_space` 를 탐색해 `primary_metric` KFold OOF 평균을 최대화하는 하이퍼파라미터를 찾습니다. 본 단계는 테스트 데이터를 절대 사용하지 않습니다 (정보 누설 방지).

옵션

키	타입	기본 값	설명
<code>enabled</code>	bool	<code>true</code>	False 면 모든 모델 튜닝 생략
<code>n_trials</code>	int	30	모델당 시도 횟수
<code>timeout</code>	int / null	<code>null</code>	모델당 wall-clock 상한(초). null = 무제한
<code>cv_folds</code>	int	3	튜닝 단계 KFold 분할 수 (보통 <code>training.cv_folds</code> 보다 작게)
<code>random_state</code>	int	42	TPE 샘플러 시드

YAML 예시

```
tuning:
  enabled: true
  n_trials: 30
  timeout: 1800          # 모델당 30분 상한
  cv_folds: 3
  random_state: 42
```

동작 메모

- 모델별 `search_space` 가 비어 있으면 그 모델은 `fixed_params` 만으로 학습하고 튜닝을 생략합니다.

- 튜닝 단계의 `early_stopping_rounds` 는 `training.early_stopping_rounds` 를 그대로 사용합니다.
- 빠른 1차 검증: `n_trials: 10` , `cv_folds: 2` . 운영 권장: `n_trials: 30~50` , `cv_folds: 3` , 필요시 `timeout` 으로 wall-clock 보호.

13. 모델 `models`

역할

활성화할 모델과 각 모델의 하이퍼파라미터 / 탐색 공간 / 손실 함수를 지정합니다. 모든 모델은 동일 인터페이스(`fit` / `predict_proba` / `feature_importance` / `shap_values`)를 따르므로 학습/ 스코어링/SHAP 경로가 모델 종류에 무관합니다.

13.1 공통 구조

`models.<name>` 의 키 (모든 모델 공통):

키	타입	기본값	설명
<code>enabled</code>	bool	<code>true</code> (ElasticNet 만 <code>false</code>)	학습에 포함 여부
<code>fixed_params</code>	dict	<code>{}</code>	항상 적용되는 라이브러리 원본 파라미터
<code>search_space</code>	dict	<code>{}</code>	Optuna 탐색 공간. 비어 있으면 튜닝 생략
<code>loss</code>	str	<code>logloss</code>	<code>logloss</code> (기본) / <code>focal</code> (Focal Loss)

`search_space` 항목 형식:

```
# 1) float - low/high 필수, log 선택(기본 false)
learning_rate: { type: float, low: 0.01, high: 0.3, log: true }

# 2) int - low/high 필수, log·step 선택(step 기본 1)
num_leaves:   { type: int,   low: 15,   high: 255 }

# 3) categorical - choices 필수
boosting_type: { type: categorical, choices: [gbdt, dart] }
```

13.2 LightGBM `lgbm`

- 범주형 처리: `pandas category dtype native`
- early stopping: `callbacks=[early_stopping(rounds)]`
- Focal Loss: 지원

```

models:
  lgbm:
    enabled: true
    fixed_params:
      objective: binary
      metric: auc
      verbose: -1
      n_estimators: 2000
    search_space:
      learning_rate: { type: float, low: 0.01, high: 0.3, log: true }
      num_leaves: { type: int, low: 15, high: 255 }
      max_depth: { type: int, low: 3, high: 12 }
      min_data_in_leaf: { type: int, low: 10, high: 100 }
      feature_fraction: { type: float, low: 0.6, high: 1.0 }
      bagging_fraction: { type: float, low: 0.6, high: 1.0 }
      reg_alpha: { type: float, low: 1.0e-8, high: 10.0, log: true } #
L1
      reg_lambda: { type: float, low: 1.0e-8, high: 10.0, log: true } #
L2
      min_gain_to_split: { type: float, low: 0.0, high: 0.5 }

```

13.3 XGBoost **xgb**

- 범주형 처리: 내부 `LabelEncoder` (학습 시 fit → 스코어링 재사용, unseen 은 -1)
- early stopping: 생성자 인자 `early_stopping_rounds` (XGB 2.x sklearn API)
- Focal Loss: 지원

```

models:
  xgb:
    enabled: true
    fixed_params:
      objective: binary:logistic
      eval_metric: auc
      tree_method: hist
      n_estimators: 2000
    search_space:
      learning_rate: { type: float, low: 0.01, high: 0.3, log: true }
      max_depth: { type: int, low: 3, high: 10 }
      subsample: { type: float, low: 0.6, high: 1.0 }
      colsample_bytree: { type: float, low: 0.6, high: 1.0 }
      min_child_weight: { type: float, low: 1.0, high: 10.0 }
      reg_alpha: { type: float, low: 1.0e-8, high: 10.0, log: true } #
L1
      reg_lambda: { type: float, low: 1.0e-8, high: 10.0, log: true } #
L2
      gamma: { type: float, low: 0.0, high: 5.0 }

```

13.4 CatBoost `catboost`

- 범주형 처리: `native` (`cat_features` 인덱스 전달)
- early stopping: 학습 인자 `early_stopping_rounds`
- iteration 키: **`iterations`** (다른 모델의 `n_estimators` 와 다름)
- Focal Loss: 지원 (`PythonUserDefinedObjective`)
- L1 정규화: 미지원 (L2 만 사용 — `l2_leaf_reg`)

```
models:
  catboost:
    enabled: true
    fixed_params:
      loss_function: Logloss
      eval_metric: AUC
      iterations: 2000          # ← n_estimators 아님!
      verbose: false
      allow_writing_files: false  # 권장 (작업 디렉토리 오염 방지)
    search_space:
      learning_rate: { type: float, low: 0.01, high: 0.3, log: true }
      depth: { type: int, low: 4, high: 8 }
      l2_leaf_reg: { type: float, low: 1.0, high: 100.0, log: true }
      random_strength: { type: float, low: 0.0, high: 10.0 }
      bagging_temperature: { type: float, low: 0.0, high: 1.0 }
```

13.5 ElasticNet `elasticnet`

- sklearn `LogisticRegression(solver='saga')` 기반 L1+L2 혼합 규제 선형 모델
- 범주형 처리: 내부 `OneHotEncoder` (학습 시 `fit`, `handle_unknown="ignore"`)
- early stopping: 무시 (sklearn 에 해당 개념 없음)
- iteration capping: 자동 면제 (부스팅 아님)
- Focal Loss: 미지원 (`loss: logloss` 만)
- 기본값 `enabled: false` — 필요 시 활성화

```
models:
  elasticnet:
    enabled: true
    fixed_params:
      max_iter: 2000          # 수렴이 안 되면 늘리기
    search_space:
      C: { type: float, low: 1.0e-3, high: 10.0, log: true }
      l1_ratio: { type: float, low: 0.0, high: 1.0 }
```

- `C` — 역규제 강도. 낮을수록 규제 강함(더 sparse).
- `l1_ratio` — 0.0 = 순수 Ridge (L2), 1.0 = 순수 Lasso (L1). 중간값은 혼합.

13.6 Focal Loss (선택)

클래스 불균형이 큰 데이터(예: positive 비율 < 5%)에서 `loss: focal` 로 전환 가능. 모델별 독립이며, LGBM/XGB/CatBoost 만 지원합니다.

```
models:
  xgb:
    loss: focal                # logloss (기본) | focal
    fixed_params:
      eval_metric: auc         # rank-기반 metric 필수 (auc, pr_auc)
      tree_method: hist
      n_estimators: 2000
      focal_gamma: 2.0         # easy-example 감쇠 지수 (기본 2.0)
      focal_alpha: 0.25        # 양성 클래스 가중 (기본 0.25)
    search_space:
      # focal 하이퍼파라미터도 탐색 가능:
      # focal_gamma: { type: float, low: 0.5, high: 4.0 }
      # focal_alpha: { type: float, low: 0.1, high: 0.9 }
```

- 호환 metric: rank-based (`auc` , `pr_auc` , `AUC`). `binary_logloss` / `Logloss` 등 절대값 기반은 raw score 에 잘못 적용되어 의미가 깨지므로 사용 금지.
- `focal_gamma` / `focal_alpha` 는 wrapper 가 pop 하므로 라이브러리 원본 인자에 전달되지 않습니다 (예약 키).

14. 앙상블 ensemble

역할

활성화된 개별 모델 학습 완료 후 추가로 앙상블 모델을 생성합니다. best 선정 시 앙상블도 후보에 포함 됩니다.

옵션

키	타입	기본값	허용 값	설명
<code>enabled</code>	bool	<code>true</code>	—	앙상블 생성 여부 (활성 모델 ≥ 2 개 필요)
<code>strategy</code>	str	<code>elasticnet_plus_best</code>	<code>elasticnet_plus_best</code> / <code>weighted_average</code>	구성 방식

키	타입	기본값	허용 값	설명
<code>elasticnet_weight</code>	float / null	null	(0, 1) 또는 null	(전자 전용) elasticnet 가중치, null = 자동

YAML 예시

기본 (ElasticNet + 나머지 best):

```
ensemble:
  enabled: true
  strategy: elasticnet_plus_best
  elasticnet_weight: null      # 점수 비례 자동 계산
  # elasticnet_weight: 0.35   # 0~1 사이 값으로 직접 지정도 가능
```

전체 모델 점수 비례 가중 평균:

```
ensemble:
  enabled: true
  strategy: weighted_average
```

동작 메모

전략별 동작 - `elasticnet_plus_best` — `elasticnet` 모델을 무조건 포함하고 나머지 활성 모델 중 `test primary_metric` 1위 1개와 결합. ElasticNet 이 비활성이면 `ValueError`. - `weighted_average` — 활성화된 모든 모델을 `test primary_metric` 점수에 비례하는 가중치로 결합. 가중치는 softmax(점수 / 합) 로 정규화.

호환성 - 앙상블의 SHAP 은 서브모델 raw-margin SHAP 의 가중 평균을 반환하므로 `auto-ml-explain` 과 완전 호환됩니다. - `cv_bagging` 과 함께 켜면 외부 앙상블은 자동 비활성화 + WARN (각 모델이 이미 fold 평균). - 앙상블이 best 로 선정되면 `best.joblib` 이 곧 앙상블입니다. `cloudpickle` 이 서브모델 전체 객체 그래프를 직렬화하므로 단일 파일로 스코어링·SHAP 모두 동작합니다.

15. 리포트 `reporting`

역할

HTML / PDF 동일 내용 리포트를 생성합니다(Jinja2 + WeasyPrint). 모델 비교표, CV(OOF) 비교, 오버핏 점검 (Train vs Test, Δ), 튜닝 결과, ROC / PR 곡선, feature importance, score 분포, confusion matrix, (활성 시) 변수 선택 결과 등을 포함합니다.

옵션

키	타입	기본값	설명
<code>output_dir</code>	str	<code>./artifacts/reports</code>	리포트와 부속 CSV 저장 디렉토리
<code>generate_html</code>	bool	<code>true</code>	HTML 생성 여부
<code>generate_pdf</code>	bool	<code>true</code>	PDF 생성 여부 (WeasyPrint 필요)
<code>title</code>	str	<code>Auto-ML Binary Classification Report</code>	리포트 제목
<code>top_importance_features</code>	int / null	<code>30</code>	feature importance 표·차트에 노출할 상위 N개. null = 전체
<code>top_selection_features</code>	int / null	<code>null</code>	변수 선택 결과 노출 상위 N개. null = 전체

YAML 예시

```
reporting:
  output_dir: ./artifacts/credit/reports
  generate_html: true
  generate_pdf: true
  title: Credit Card Default Auto-ML Report
  top_importance_features: 30
  top_selection_features: null
```

동작 메모

- WeasyPrint 시스템 의존성이 없으면 PDF 생성에 실패합니다 — `generate_pdf: false` 로 명시적으로 끄거나 §3 의 시스템 패키지를 설치하세요. PDF 실패해도 HTML 은 정상 생성됩니다.
- 부속 CSV (`feature_importance.csv` , `feature_selection.csv`) 는 항상 전체 변수를 저장합니다 (`top_*` 옵션은 HTML 표시에만 영향).

- best 가 아닌 모형마다 별도 sub-report 가 자동 생성됩니다 (`output_dir/sub/<name>/report.{html,pdf}`).

16. 스코어링 `scoring`

역할

`auto-ml-score` 가 사용하는 옵션. 학습된 `best.joblib` 으로 새 데이터에 점수를 매겨 Parquet 으로 출력합니다.

옵션

키	타입	기본값	설명
<code>input_path</code>	str	<code>./data/score_input.parquet</code>	스코어링 대상 Parquet 경로
<code>output_path</code>	str	<code>./artifacts/scores/scores.parquet</code>	결과 저장 경로
<code>id_columns</code>	list[str]	<code>[]</code>	결과에 보존할 식별자 (override)
<code>threshold</code>	float	<code>0.5</code>	<code>predict_proba</code> → 0/1 변환 임계값

YAML 예시

```
scoring:
  input_path: ./data/score_input.parquet
  output_path: ./artifacts/scores/scores.parquet
  id_columns:
    - user_id
  threshold: 0.5
```

동작 메모

- 결과 컬럼: `<id_columns> + score + prediction`.
- `id_columns` 우선순위: (1) `scoring.id_columns` → (2) top-level `id_columns` → (3) artifact 메타데이터에 저장된 학습 시점 `id_columns`. 보통 top-level 에 한 번 적어두면 충분합니다.
- 스코어링 입력은 학습 시점의 features 정의(+ 변수 선택 결과)와 동일 컬럼 셋이어야 합니다. 컬럼이 빠지면 명시적 에러.
- `threshold` 는 도메인에 따라 조정 (예: false-negative 비용이 크면 0.3 으로 낮춤).

17. SHAP 해석 `explain`

역할

`auto-ml-explain` 이 사용하는 옵션. 학습된 모델이 각 행을 왜 그렇게 예측했는지 건별·변수별 기여도(SHAP) 를 산출해 Parquet 으로 저장합니다. LGBM/XGB/CatBoost 는 native API (`pred_contrib`), ElasticNet 은 `shap.LinearExplainer` , 앙상블은 서브모델 SHAP 의 가중 평균을 사용합니다.

옵션

키	타입	기본값	설명
<code>input_path</code>	str	<code>./data/score_input.parquet</code>	해석 대상 Parquet (보통 스코어링 입력과 동일)
<code>output_path</code>	str	<code>./artifacts/explanations/shap.parquet</code>	결과 저장 경로
<code>id_columns</code>	list[str]	<code>[]</code>	결과 식별자 (override). 스코어링과 동일 우선순위

YAML 예시

```
explain:
  input_path: ./data/score_input.parquet
  output_path: ./artifacts/explanations/shap.parquet
  id_columns:
    - user_id
```

출력 스키마

`<id_columns> + shap_<feature_1> + shap_<feature_2> + ... + base_value + score`

- `base_value`: 모델의 평균 예측 확률 (각 행 동일).
- `shap_<feature>`: 해당 변수가 평균 대비 예측을 얼마나 끌어올렸/내렸는지 (확률 도메인).
- `score`: 최종 예측 확률 (= `scoring` 의 `score` 와 동일).
- 가법성 보장: 모든 행에서 `base_value + sum(shap_*) ≈ score` (오차 $\leq 1e-12$).

동작 메모

native API 는 raw-margin (logit) 도메인 SHAP 을 반환합니다. 본 라이브러리는 다음과 같이 확률 도메인으로 변환하면서 가법성을 보존합니다.


```
p_base = sigmoid(base_raw)
p_pred = sigmoid(base_raw + sum(feature_raw))
shap_prob[i] = feature_raw[i] / sum(feature_raw) * (p_pred - p_base)
```

비율은 raw 도메인 그대로 유지되고, 합산만 (score - base_value) 와 정확히 일치하도록 스케일링 됩니다.

18. 로깅 logging

역할

학습/스코어링/SHAP 실행마다 stage 별 별도 로그 파일을 자동 생성합니다.

옵션

키	타입	기본값	허용 값	설명
log_dir	str	./artifacts/ logs	—	파일 로그 저장 디렉토리
level	str	INFO	DEBUG / INFO / WARNING / ERROR	로깅 레벨
to_stdout	bool	true	—	콘솔 출력 여부
to_file	bool	true	—	파일 출력 여부

YAML 예시

```
logging:
  log_dir: ./artifacts/logs
  level: INFO
  to_stdout: true
  to_file: true
```

동작 메모

- 파일명은 train_YYYYMMDD_HHMMSS.log / score_YYYYMMDD_HHMMSS.log / explain_YYYYMMDD_HHMMSS.log 형식으로 stage 별 분리됩니다.
- 콘솔과 파일은 동시에 활성화 가능. to_file: false 면 파일은 만들어지지 않습니다.
- 각 로그에는 시작/종료 마커, 단계별 진행, 모델 튜닝 결과, 산출물 경로, 총 소요 시간이 포함됩니다
— 문제 추적의 1차 자료.

부록

A. CLI 명령어 모음

명령	진입점	용도
<code>auto-ml-train --config <yaml></code>	<code>auto_ml.pipeline:cli_train</code>	학습 파이프라인
<code>auto-ml-score --config <yaml></code>	<code>auto_ml.scoring.runner:cli_score</code>	배치 스코어링
<code>auto-ml-explain --config <yaml></code>	<code>auto_ml.explain.runner:cli_explain</code>	SHAP 해석
<code>auto-ml-set-best --config <yaml> --model <name></code>	<code>auto_ml.cli.set_best:cli_set_best</code>	재학습 없이 best 교체

`auto-ml-set-best` 예시:

```
# xgb 후보를 best 로 승격
auto-ml-set-best --config configs/my_config.yaml --model xgb

# 앙상블 후보를 best 로 승격
auto-ml-set-best --config configs/my_config.yaml --model ensemble
```

승격된 best 의 metadata 에는 `promoted_at` / `promoted_from` (이전 best 이름) 이 기록됩니다.

B. 산출물 안내

B.1 `best.joblib` (학습 산출물)

전처리 + 모델 + 메타데이터가 하나의 파일로 묶인 cloudpickle+gzip 번들입니다. 스코어링 / SHAP 시 이 파일 하나만 있으면 됩니다.

전체 sub-artifact 구조:

<code><artifact_dir>/best.joblib</code>	← 운영용 (scoring/explain 대상)
<code><artifact_dir>/models/lgbm.joblib</code>	← 후보 1
<code><artifact_dir>/models/xgb.joblib</code>	← 후보 2
<code><artifact_dir>/models/catboost.joblib</code>	← 후보 3

```
<artifact_dir>/models/elasticnet.joblib    ← 후보 4 (enabled 시)
<artifact_dir>/models/ensemble.joblib     ← 앙상블 후보 (enabled 시)
```

`best.joblib` 은 위 sub-artifact 중 하나의 복사본입니다. 각 sub-artifact 는 독립 번들이라 그 자체로 `auto-ml-score` / `auto-ml-explain` 호환입니다.

B.2 HTML / PDF 리포트

`reporting.output_dir/report.html` 을 브라우저로 열면 다음 섹션을 볼 수 있습니다.

- 모델 비교표 (CV / Test 점수)
- 오버핏 점검 (Train vs Test, Δ)
- 튜닝 결과 (Optuna 가 찾은 best params)
- ROC / PR 곡선
- Feature importance (gain 기준)
- Score 분포 히스토그램
- Confusion matrix
- (활성 시) 변수 선택 결과 (frequency 막대 + 채택/제외 라벨)

PDF 도 동일 내용입니다.

B.3 `scores.parquet` (스코어링 산출물)

```
user_id, score, prediction
1001,    0.87,  1
1002,    0.12,  0
```

- `score` — 0~1 사이 확률값
- `prediction` — `score >= scoring.threshold` 면 1, 아니면 0

B.4 `test_predictions.parquet` (학습 부산물)

학습 시 best 모델의 holdout 예측을 함께 export 합니다: `<artifact_dir>/../predictions/test_predictions.parquet`, 스키마 `<id_columns> + score + prediction + <target_column>`. 외부 BI / 추가 진단용 (overfit 검증, 임계값 튜닝 등).

B.5 SHAP 산출물

§17 출력 스키마 참고.

B.6 로그 파일

`artifacts/logs/train_YYYYMMDD_HHMMSS.log` 에 단계별 진행, 모델 튜닝 결과, 산출물 경로, 총 소요시간이 기록됩니다. 문제 발생 시 가장 먼저 보는 곳입니다.

C. 트러블슈팅 FAQ

Q1. **auto-ml-train: command not found** 가상환경 활성화 여부 확인. 프롬프트 앞에 `(.venv)` 가 보여야 합니다. 안 보이면 `source .venv/bin/activate` 다시 실행.

Q2. **ValueError: target column must contain only 0 and 1** 타깃 컬럼에 0/1 외 값(NaN, 2, "yes" 등)이 섞임. 데이터 정리 후 재시도.

Q3. **ValueError: column X is all NaN** 어떤 수치형 컬럼이 학습 데이터에서 전부 결측. 다음 중 하나로 해결: - `features.csv` 에서 해당 컬럼 `used: false` - `preprocessing.numeric_null_strategy: constant` 로 전환 - 데이터 자체 정리

Q4. PDF 리포트가 안 만들어져요 WeasyPrint 시스템 의존성 누락. HTML 은 정상 생성됩니다. PDF 가 필요하면 §3 의 시스템 패키지 설치, 아니면 `reporting.generate_pdf: false` 로 끄세요.

Q5. 학습이 너무 오래 걸립니다 다음을 줄이세요:

```
tuning:
  n_trials: 10          # 30 → 10
  cv_folds: 2           # 3 → 2
training:
  cv_folds: 3           # 5 → 3
```

또는 `tuning.timeout: 1800` (30분) 으로 wall-clock 상한 지정.

Q6. 모델 한 개만 쓰고 싶어요 `models.<name>.enabled: false` 로 나머지를 끄세요. 최소 1개는 켜져 있어야 합니다.

Q7. 임계값을 0.5 가 아닌 값으로 `scoring.threshold: 0.3` 처럼 변경 (0.3 이상이면 1로 분류).

Q8. 스코어링 입력에 컬럼 하나가 없어요 학습 시 `features` 정의가 `best.joblib` 메타데이터에 박혀 있어 동일 컬럼 셋이 필요합니다. 빠진 컬럼이 있으면 명시적 에러로 알려줍니다. 일시 누락이면 컬럼만 NaN 으로 채워 다시 실행하세요(라이브러리가 자동으로 학습 시 기본값으로 채웁니다).

Q9. 오버핏 Δ 가 너무 큼니다 [§11 최종 모델 학습 전략](#)의

`final_fit_strategy: iteration_capping` 또는 `cv_bagging` 으로 전환을 검토하세요. 테스트셋이 학습 신호로 노출되는 편향을 제거합니다.

Q10. ElasticNet 만 Focal Loss 가 안 됩니다 지원하지 않는 조합입니다. `models.elasticnet.loss: logloss` (기본값) 로 두세요.

D. 폐쇄망 이관

다음 4가지만 옮기면 됩니다.

1. 패키지 wheel 묶음 — 외부망에서 미리 만들어 둡니다. `bash pip wheel -r requirements.txt -w wheelhouse/`
2. 본 저장소 자체 — `git clone` 한 폴더 그대로.
3. 학습 산출물 — `artifacts/models/best.joblib`
4. 스코어링용 설정 YAML

폐쇄망에서 설치:

```
pip install --no-index --find-links=wheelhouse -r requirements.txt
pip install -e .
auto-ml-score --config configs/my_config.yaml
```

PDF 리포트가 필요하면 WeasyPrint 시스템 의존성(libpango 등)도 함께 배포하세요.

E. 용어 사전

용어	설명
이진 분류	0/1 (참/거짓) 두 가지 중 하나를 맞히는 문제
타겟 (target)	예측 대상 컬럼 (0 또는 1)
피처 (feature)	예측의 근거가 되는 입력 변수
전처리	결측 채우기, 이상치 자르기, 스케일링 등 학습 전 데이터 정리
스케일링	변수마다 다른 단위를 비슷한 크기로 맞춤
이상치	분포에서 극단적으로 동떨어진 값
Skew (왜도)	분포가 한쪽으로 치우친 정도
Stability Selection	부분표본을 여러 번 뽑아 자주 선택되는 변수만 추리는 절차 (Meinshausen & Bühlmann, 2010)
Optuna / TPE	베이지안 하이퍼파라미터 탐색 라이브러리·알고리즘
하이퍼파라미터	학습 전 사람이 정하는 설정값 (학습률, 트리 깊이 등)
KFold / OOF	데이터 K 등분 후 돌아가며 평가. Out-Of-Fold 예측으로 안정적 점수 산출
Early stopping	검증셋 점수가 일정 라운드 개선되지 않으면 학습 조기 종료
ROC-AUC	분류 성능 지표 (0.5=찍기, 1.0=완벽). 본 라이브러리 기본 지표

용어	설명
PR-AUC	Precision-Recall 곡선 아래 면적. positive 비율이 매우 낮을 때 권장
KS statistic	Kolmogorov-Smirnov 통계. 신용평점 도메인 표준 지표
Focal Loss	어려운 샘플에 학습 신호를 집중시키는 손실 (Lin et al. 2017). 불균형 데이터 대응
SHAP	건별·변수별 예측 기여도. Shapley value 기반
Artifact	학습 결과물(모델 + 전처리기 + 메타데이터) 단일 번들 파일
Parquet	컬럼 기반 효율적 데이터 파일 형식 (CSV 보다 빠르고 작음)

문제가 풀리지 않으면 `artifacts/logs/` 의 최신 로그 파일과 함께 담당자에게 공유해 주세요.